

```
In [1]: import pandas as pd
import numpy as np
import missingno as msno
import matplotlib.pyplot as plt
```

```
In [2]: df = pd.read_csv("../data/StudentsPerformance.csv") #Importación inicial del archiv
```

Análisis de rendimiento académico de estudiantes - Big Data IDIA 222

Con el fin de probar la reproductibilidad de archivos de código python mediante la aplicación de conocimientos previos sobre el manejo de repositorios y clonación de entornos para su ejecución, se realizará un trabajo de análisis y procesamiento de datos con determinados parámetros (sobre librerías, enfáticamente) para su posterior reproducción en una máquina tercera.

```
In [3]: #Despliegue inicial de CSV para verificar importación
df
```

Out[3]:

	gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score
0	female	group B	bachelor's degree	standard	none	72	72	74
1	female	group C	some college	standard	completed	69	90	88
2	female	group B	master's degree	standard	none	90	95	93
3	male	group A	associate's degree	free/reduced	none	47	57	44
4	male	group C	some college	standard	none	76	78	75
...	...	...	...	...	...	...	...	...
995	female	group E	master's degree	standard	completed	88	99	95
996	male	group C	high school	free/reduced	none	62	55	55
997	female	group C	high school	free/reduced	completed	59	71	65
998	female	group D	some college	standard	completed	68	78	77
999	female	group D	some college	free/reduced	none	77	86	86

1000 rows × 8 columns

Exploración inicial

Lo primero siempre se tratará de conocer la base de datos con la que estamos trabajando, en este proceso se examinan detalles como:

- número de registros
- Número de columnas
- Número de variables
- Tipos de datos
- Valores nulos (o faltantes)
- Duplicados (ya sea registros o columnas)
- Estadística descriptiva

```
In [4]: print("Exploración inicial")
print("Número de registros: ", df.shape[0]*df.shape[1])
```

```
print("Número de columnas: ", df.shape[1])
print("Número de filas: ", df.shape[0])
```

Exploración inicial

Número de registros: 8000

Número de columnas: 8

Número de filas: 1000

In [5]: *#Para tipos de datos, esperando encontrar datos categóricos como "str" y numéricos*
df.dtypes

```
Out[5]: gender                str
        race/ethnicity        str
        parental level of education  str
        lunch                 str
        test preparation course    str
        math score             int64
        reading score          int64
        writing score           int64
        dtype: object
```

In [6]: *#Para evaluación de datos nulos, se opta por realizar el análisis por columna y por*
df.isnull().mean()*100

```
Out[6]: gender                0.0
        race/ethnicity        0.0
        parental level of education  0.0
        lunch                 0.0
        test preparation course    0.0
        math score             0.0
        reading score          0.0
        writing score           0.0
        dtype: float64
```

In [7]: *#Para la verificación de duplicados en ambas columnas y filas:*
duplicados_filas = df[df.duplicated()]

print("Filas duplicadas:")
duplicados_filas

duplicados_columnas = df.columns[df.columns.duplicated()]

print("Columnas duplicadas:")

if len(duplicados_columnas) > 0:
 display(pd.DataFrame({"Columnas duplicadas": duplicados_columnas}))
else:
 display(pd.DataFrame())

Filas duplicadas:

Columnas duplicadas:

In [8]: *#Estadística descriptiva (variables categóricas)*
df.describe(include="str")

Out[8]:

	gender	race/ethnicity	parental level of education	lunch	test preparation course
count	1000	1000	1000	1000	1000
unique	2	5	6	2	2
top	female	group C	some college	standard	none
freq	518	319	226	645	642

In [9]: *#Estadística descriptiva (datos numéricos)*
df.describe()

Out[9]:

	math score	reading score	writing score
count	1000.00000	1000.000000	1000.000000
mean	66.08900	69.169000	68.054000
std	15.16308	14.600192	15.195657
min	0.00000	17.000000	10.000000
25%	57.00000	59.000000	57.750000
50%	66.00000	70.000000	69.000000
75%	77.00000	79.000000	79.000000
max	100.00000	100.000000	100.000000

De forma general podemos ver que el dataframe inicial con el que trabajamos tiene un buen estado en lo que concierne a duplicados y/o nulos, ya que de ninguno de los dos se encontraron registros que puedan afectar al uso del mismo. Con esto se puede comenzar a hacer evaluaciones e identificación de patrones, aunque la estadística descriptiva ya revela, cuando menos, los patrones más elementales de comportamiento de los datos.

Limpieza y preprocesamientos

Como comprobamos en el punto anterior, el dataframe inicial presenta un buen estado de salud considerando que no existen duplicados ni nulos; por otro lado, únicamente se hará una evaluación sobre valores posibles para identificar:

- En variables categóricas: todas las respuestas únicas que hay disponibles
- En variables numéricas: rangos de valores

Esto con el fin de corroborar si no existen datos "extraños" en el dataframe.

In [10]: *#Análisis de valores únicos en variables categóricas*
col_cat = ["gender", "race/ethnicity", "parental level of education", "lunch", "test preparation course"]
for col in col_cat:

```
print()
print(f"Columna: {col}")
print(f"Total de observaciones: {df[col].count()}")
tabla = pd.DataFrame({
    "Frecuencia": df[col].value_counts()
})
display(tabla)
```

Columna: gender

Total de observaciones: 1000

Frecuencia

gender

female	518
male	482

Columna: race/ethnicity

Total de observaciones: 1000

Frecuencia

race/ethnicity

group C	319
group D	262
group B	190
group E	140
group A	89

Columna: parental level of education

Total de observaciones: 1000

Frecuencia

parental level of education

some college	226
associate's degree	222
high school	196
some high school	179
bachelor's degree	118
master's degree	59

Columna: lunch

Total de observaciones: 1000

Frecuencia	
lunch	
standard	645
free/reduced	355

Columna: test preparation course
Total de observaciones: 1000

Frecuencia	
test preparation course	
none	642
completed	358

```
In [11]: #Análisis de rango de valores en variables numéricas.
col_num = ["math score", "reading score", "writing score"]
for col in col_num:
    print()
    print(f"Columna: {col}, mínimo: {df[col].min()}, Máximo: {df[col].max()}")
```

Columna: math score, mínimo: 0, Máximo: 100

Columna: reading score, mínimo: 17, Máximo: 100

Columna: writing score, mínimo: 10, Máximo: 100

Con estas observaciones podemos descartar si hay o no algun dato irregular o que no pertenezca a las respuestas esperadas del dataframe. A pesar de ello, no se encontró ningún dato irregular, por lo que no es necesario realizar limpieza ni procesos especiales al momento.

Clasificación de rendimiento por calificación promedio

En este apartado se creará una nueva variable que englobe, de cada registro, el promedio general de las tres materias para tomar de referencia para una clasificación del rendimiento académico del estudiante.

La ponderación del mismo será dividida en cinco categorías basadas en el rango de calificación final que tenga:

- Excelente (Excellent): 95-100
- Potencial (Potential): 90-94.9999
- Sobresaliente (Outstanding): 80-89.9999
- Suficiente (Enough): 70-79.9999
- Deficiente (Deficient): <70

Originalmente se planteaba la posibilidad de incluir de referencia el uso de la categoría "test preparation course" ya que este indica si se hizo un curso de preparación previo al examen; se pensaba que, si el alumno tenía una calificación de entre 90 y 100 sin haber hecho el examen, podría considerarse "sobresaliente" al no contar con preparación, sin embargo la idea se descartó al considerarse irrelevante y que siempre existe estudio del que no se tiene constancia por parte del personal docente (cosa que en el margen de los hechos, es más común).

```
In [12]: # creación de variable con el promedio general de cada alumno
df["Average_Final"] = df[
    ["math score", "reading score", "writing score"]
].mean(axis=1)
df.head()
```

```
Out[12]:
```

	gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score	A
0	female	group B	bachelor's degree	standard	none	72	72	74	
1	female	group C	some college	standard	completed	69	90	88	
2	female	group B	master's degree	standard	none	90	95	93	
3	male	group A	associate's degree	free/reduced	none	47	57	44	
4	male	group C	some college	standard	none	76	78	75	

```
#Creación de variable con ponderación general de rendimiento basado en condición en variable "Average_Final" Condition = [
(df["Average_Final"] >=95), (df["Average_Final"] >=90) & (df["Average_Final"] <95), (df["Average_Final"] >=80) &
(df["Average_Final"] <90), (df["Average_Final"] >=70) & (df["Average_Final"] <80), (df["Average_Final"] <70) ] Classes = [
"Excellent", "Potential", "Outstanding", "Enough", "Deficient" ] df["Performance"] = np.select(Condition, Classes,
default="insuficiente") df.head()
```

Respuesta a preguntas sobre la información:

¿Cuál de las tres áreas tiene el promedio más alto?

Este análisis se puede obtener con un comando ejecutado anteriormente:

```
df.describe()
```

```
In [13]: df.describe()
```

Out[13]:

	math score	reading score	writing score	Average_Final
count	1000.00000	1000.000000	1000.000000	1000.000000
mean	66.08900	69.169000	68.054000	67.770667
std	15.16308	14.600192	15.195657	14.257326
min	0.00000	17.000000	10.000000	9.000000
25%	57.00000	59.000000	57.750000	58.333333
50%	66.00000	70.000000	69.000000	68.333333
75%	77.00000	79.000000	79.000000	77.666667
max	100.00000	100.000000	100.000000	100.000000

R: El área de lectura (reading) es la que cuenta con el promedio general (de los 1000 alumnos) más alto, con un 69.19, seguido de el área de escritura (writing) con 98.05.

¿Los estudiantes que realizaron el curso de preparación presentan mejores resultados?

Este análisis se puede hacer si verificamos el promedio de calificaciones considerando la columna sobre el curso de preparación como referencia; se filtran los registros con el criterio sobre la variable mencionada, de forma que tenemos dos dataframes de menor escala, y de cada uno obtenemos el promedio general a partir de una descripción (`df.describe`) de la columna `Average_Final`.

```
In [14]: # Crea un dataframe nuevo y diferente basado en la respuesta de la variable sobre e
df_completed = df[df["test preparation course"] == "completed"]

df_none = df[df["test preparation course"] == "none"]

In [15]: df_completed.describe()
```

Out[15]:

	math score	reading score	writing score	Average_Final
count	358.000000	358.000000	358.000000	358.000000
mean	69.695531	73.893855	74.418994	72.669460
std	14.444699	13.638384	13.375335	13.036960
min	23.000000	37.000000	36.000000	34.333333
25%	60.000000	65.000000	66.000000	65.000000
50%	69.000000	75.000000	76.000000	73.500000
75%	79.000000	84.000000	83.000000	82.166667
max	100.000000	100.000000	100.000000	100.000000

In [16]: df_none.describe()

Out[16]:

	math score	reading score	writing score	Average_Final
count	642.000000	642.000000	642.000000	642.000000
mean	64.077882	66.534268	64.504673	65.038941
std	15.192376	14.463885	14.999661	14.186707
min	0.000000	17.000000	10.000000	9.000000
25%	54.000000	57.000000	54.000000	55.416667
50%	64.000000	67.000000	65.000000	65.333333
75%	74.750000	76.000000	74.000000	75.000000
max	100.000000	100.000000	100.000000	100.000000

Con este análisis podemos revelar el promedio final de, solamente, los registros que en la variable `test preparation course` tengan por valor ya sea `none` o `completed`.

R: En general, los estudiantes que *si* concluyeron el curso tienden a tener mayor calificación, teniendo un promedio general de 72.66, por lo tanto **sí**, tienen mejor rendimiento.

¿Qué porcentaje de estudiantes alcanza un promedio de valoración "sobresaliente" (outstanding) o superior?

Este análisis es similar al anterior en el sentido de que establece una condición para realizar un conteo de falsos y verdaderos, esta vez, basado en el valor de `Average_Final`.

Se estableció previamente que la clase `Outstanding` es para calificaciones de 80 o superiores, por lo que se tomará el criterio numérico ya que reduce la cantidad de condiciones que habría que declarar si se escribe verbalmente.

Cada condición se guarda en una variable que ayudará a asignar un valor final para impresión; lo que revelará el porcentaje de la ponderación binarizada (más parecido a aprobado/reprobado).

```
In [17]: Outstanding = df["Average_Final"] >= 80
Barely = df["Average_Final"] < 80

print(f"{Outstanding.mean()*100}% de los estudiantes tiene un rendimiento sobresali
print(f"{Barely.mean()*100}% de los estudiantes tiene un rendimiento apenas suficie
```

19.8% de los estudiantes tiene un rendimiento sobresaliente o mejor

80.2% de los estudiantes tiene un rendimiento apenas suficiente o deficiente

R: Podemos ver que un porcentaje relativamente bajo tiene un promedio sobresaliente o superior, siendo de poco menos del 20% aquellos que cuentan con una calificación final de 80 o mayor.

¿Cuál es el grupo con menor promedio y cuál es el que tiene el mayor?

Este análisis vuelve a realizar un filtrado por variable para crear dataframes reducidos con respecto al valor de la misma; en este caso relacionando cada uno con los grupos que hay. Se cuentan con 5 grupos, del A al E, por lo que se crearán las variables condicionadas con respecto a esto. para después realizar una descripción estadística de cada uno.

```
In [18]: #Asignación y creación de nuevas variables por grupo de población
df_A = df[df["race/ethnicity"] == "group A"]
df_B = df[df["race/ethnicity"] == "group B"]
df_C = df[df["race/ethnicity"] == "group C"]
df_D = df[df["race/ethnicity"] == "group D"]
df_E = df[df["race/ethnicity"] == "group E"]
```

```
In [19]: df_A.describe()
```

```
Out[19]:
```

	math score	reading score	writing score	Average_Final
count	89.000000	89.000000	89.000000	89.000000
mean	61.629213	64.674157	62.674157	62.992509
std	14.523008	15.543762	15.468278	14.444598
min	28.000000	23.000000	19.000000	23.333333
25%	51.000000	53.000000	51.000000	52.000000
50%	61.000000	64.000000	62.000000	61.333333
75%	71.000000	74.000000	73.000000	73.000000
max	100.000000	100.000000	97.000000	96.333333

```
In [20]: df_B.describe()
```

```
Out[20]:
```

	math score	reading score	writing score	Average_Final
count	190.000000	190.000000	190.000000	190.000000
mean	63.452632	67.352632	65.600000	65.468421
std	15.468191	15.177499	15.625173	14.732133
min	8.000000	24.000000	15.000000	18.333333
25%	54.000000	56.000000	55.250000	56.666667
50%	63.000000	67.000000	67.000000	65.000000
75%	74.000000	79.750000	78.000000	76.833333
max	97.000000	97.000000	96.000000	96.666667

```
In [21]: df_C.describe()
```

```
Out[21]:
```

	math score	reading score	writing score	Average_Final
count	319.000000	319.000000	319.000000	319.000000
mean	64.463950	69.103448	67.827586	67.131661
std	14.852666	13.997033	14.983378	13.872211
min	0.000000	17.000000	10.000000	9.000000
25%	55.000000	60.000000	57.000000	57.666667
50%	65.000000	71.000000	68.000000	68.333333
75%	74.000000	78.500000	79.000000	77.000000
max	98.000000	100.000000	100.000000	98.666667

```
In [22]: df_D.describe()
```

Out[22]:

	math score	reading score	writing score	Average_Final
count	262.000000	262.000000	262.000000	262.000000
mean	67.362595	70.030534	70.145038	69.179389
std	13.769386	13.895306	14.367707	13.252776
min	26.000000	31.000000	32.000000	31.000000
25%	59.000000	60.250000	61.000000	60.333333
50%	69.000000	71.000000	72.000000	70.000000
75%	77.000000	79.000000	80.000000	78.583333
max	100.000000	100.000000	100.000000	99.000000

In [23]: `df_E.describe()`

Out[23]:

	math score	reading score	writing score	Average_Final
count	140.000000	140.000000	140.000000	140.000000
mean	73.821429	73.028571	71.407143	72.752381
std	15.534259	14.874024	15.113906	14.565016
min	30.000000	26.000000	22.000000	26.000000
25%	64.750000	63.000000	62.000000	64.666667
50%	74.500000	74.000000	72.000000	73.500000
75%	85.000000	84.000000	80.250000	82.416667
max	100.000000	100.000000	100.000000	100.000000

Con este análisis podemos ver los promedios generales de cada grupo, nuevamente basándonos en la variable `Average_Final`

R: Podemos ver que el **grupo E** tiene el mayor promedio, con 72.75 de promedio general Mientras que el **grupo A** es el que tiene el menor de todos, con 65.99 de promedio general

Esto puede revelar un patrón que podría plantear una posibilidad sobre un criterio de elección de los alumnos de cada grupo, o al menos un patrón muy notorio entre los mismos.

Visualizaciones de datos:


La visualización es la parte que se encarga de mostrar diferentes características de los datos como su comportamiento, consistencia, y de más atributos que pueden denotarse de los mismos; muchos de estos son despliegues gráficos de los cuales hay muchos tipos, pero que revelan información diferente dependiendo de cuál sea el propósito.

Se usarán tres gráficas para revelar los siguientes factores:

- **Nulidad de datos:** demuestra con gráficas de columnas apiladas al 100% la posición de datos íntegros, y deja un espacio en blanco en el lugar en donde hayan datos nulos. Esto es útil para tener un despliegue visual del estado de integridad del dataframe que revele también la posición (observación) en donde determinado dato nulo se encuentra, y sirve para tomar decisiones con respecto a la variable o las observaciones involucradas.
- **Promedio por grupo:** a través de histograma convencional, se demostrará la magnitud relativa de los promedios obtenidos por cada grupo; esto ayudará a denotar un patrón que se detectó en el último análisis realizado, en que se encontró que entre los grupos existe una curva de calificaciones de/crecientes conforme al abecedario de grupos.
- **Distribución de género:** con una gráfica de pastel binaria se determinará de una forma abstracta el porcentaje de hombres y de mujeres que hay en la población estudiada.

```
In [24]: #Gráfico: Matriz de nulos (columnas apiladas al 100%)  
msno.matrix(df, figsize=(10,6))
```

Out[24]: <Axes: >



Podemos observar, al igual que encontramos en los análisis exploratorios, que el dataset se encuentra completamente íntegro en lo que respecta a presencia de datos, en caso de haber tenido datos nulos, las columnas presentarían espacios en blanco en puntos determinados de las mismas, indicando no solo la presencia sino la ubicación del o los datos faltantes.


```
In [25]: #Gráfico: Barras (grupo/calificación)
Av = df["Average_Final"]
Calif = df.groupby("race/ethnicity")["Average_Final"].mean()

#Creación de histograma
plt.figure(figsize=(8,6))
Calif.plot(kind="bar", color="skyblue", edgecolor="black")

#Líneas de promedio general de escuela
plt.axhline(df["Average_Final"].mean(),color="red", linestyle="--", linewidth=2, la

#Detalles de gráfica
plt.title("Promedio de calificación por grupo")
plt.xlabel("Grupo")
plt.ylabel("Promedio final")
plt.legend()

plt.show()
```



Podemos observar algo que cuando menos despierta curiosidad al ver que los grupos, en el orden en el que están, tienen una curva de calificaciones creciente, siendo el A el de menor promedio, pasando por B como el siguiente mejor, C el siguiente, D el siguiente y por último el E como el mejor de todos.

También podemos encontrar que solo dos grupos sobresalen del promedio general, siendo el grupo D y el E los que, con este criterio, podrían ser llamados "sobresalientes", en ese aspecto.


```
In [26]: # Grafico: pastel (género)
g = df["gender"]
frecuencias = g.value_counts()

#Creación de histograma
plt.pie(frecuencias, labels=frecuencias.index, autopct="%1.1f%%", startangle=90, co

#Detalles de gráfica
plt.title("Distribución de género")

plt.show()
```

Distribución de género



Con sencillez podemos notar que la población femenina tiene un ligero predominio sobre la masculina, al menos en masa; esto es una métrica básica para una población cualquiera.

Conclusiones generales

Ya que el dataset no contuvo ningún problema de integridad, fue sencillo proceder con un análisis directo de métricas elementales y algunas más específicas, se encontró un gran porcentaje de estudiantes con calificaciones bajas, especialmente si se fija en el promedio general siendo de menos de 70, con solo dos grupos que rebasan esta medida. Si se habla de hazañas o un desempeño más sobresaliente, solo un 20% alcanza o supera esta consideración.

Así mismo se encontró un patrón notorio entre los grupos, teniendo una mayor concentración de promedio más alto en un grupo que en otros. Más allá de la curva que se hace con las calificaciones ordenadas por grupo, es útil saber cómo se distribuyen los promedios ya que así se pueden realizar ajustes para juntar alumnos de mayor rendimiento con otros que tengan uno más deficiente para que estos puedan ayudar a sus compañeros que lo requieran y estabilizar la métrica aún más.

Esta es una prueba de cómo el manejo y análisis de datos puede contribuir a la toma de decisiones estratégicas que ayuden al crecimiento de cierta entidad moral.

In []: